

L'anatomie d'un grand café arabica

Quels critères définissent objectivement un café d'exception ?



Cours : Introduction au Traitement de Données

Formation : MAM3 — Mathématiques Appliquées et Modélisation

Établissement : Polytech Nice Sophia — Université Côte d'Azur

Année : 2025-2026

Dataset : CQI Arabica Coffee Quality Dataset (Kaggle)

Dépôt Git : [\[URL du dépôt Git\]](#)

Contents

1 Business Goal — Le café, un objet de science	2
1.1 Contexte et motivation	2
1.2 Utilité du dataset	2
2 Gestion d'équipe	2
2.1 Organisation du travail	2
2.2 Répartition des rôles	3
3 Description des données	3
3.1 Vue d'ensemble	3
3.2 Statistiques descriptives des critères sensoriels	3
3.3 Nettoyage et wrangling	3
4 Visualisation des données	4
4.1 Corrélations entre les critères sensoriels	4
4.2 Profil sensoriel selon la méthode de traitement	5
4.3 Scores par pays d'origine	6
4.4 Influence de l'altitude	6
5 Feature Engineering	7
5.1 Variables directement disponibles (features brutes)	7
5.2 Features construites	7
5.2.1 Score de qualité sensorielle globale	7
5.2.2 Pénalité de défauts	7
5.2.3 Encodage de l'altitude	7
5.2.4 Encodage de la méthode de traitement	7
5.3 Vérification de la pertinence des features	8
6 Régression linéaire et logistique	8
6.1 Régression linéaire : prédire le score total	8
6.1.1 Modèle	8
6.1.2 Résultats	8
6.2 Régression logistique : identifier les cafés d'exception	9
6.2.1 Définition de la cible	9
6.2.2 Modèle LOGIT	9
6.2.3 Résultats	10
7 Conclusion	10
7.1 Enseignements de l'analyse	10
7.2 Limites et perspectives	10
Références	11

1. Business Goal — Le café, un objet de science

1.1. Contexte et motivation

Le café est l'une des boissons les plus consommées au monde, avec plus de 2,5 milliards de tasses bues chaque jour. Pourtant, la frontière entre un café ordinaire et un café d'*exception* reste souvent floue pour le consommateur. Pour les professionnels du secteur — torréfacteurs, importateurs, baristas — cette question est au cœur de décisions économiques majeures.

Le **Coffee Quality Institute (CQI)** propose un protocole d'évaluation sensorielle rigoureux, le *cupping score*, qui décompose la qualité d'un café en huit critères objectifs, chacun noté de 6 à 10. Le score total (*Total Cup Points*) est la somme de ces sous-scores. Un café atteignant 80 points ou plus est qualifié de *Specialty Coffee* — la crème de la crème.

Question de recherche : Quels sont les facteurs — sensoriels, géographiques, variétaux et agronomiques — qui permettent de prédire et d'expliquer la qualité d'un café arabica noté par le CQI ?

1.2. Utilité du dataset

Le dataset `df_arabica_clean.csv` (source : Kaggle, CQI) regroupe **207 échantillons** de cafés arabica certifiés, notés entre 2021 et 2023, provenant de **23 pays**. Il constitue une source idéale pour répondre à notre question car :

- Les notes sensorielles sont **standardisées** par des juges certifiés Q-Grader ;
- Il couvre une grande diversité géographique, variétale et de méthodes de traitement ;
- Il comprend à la fois des variables continues, catégorielles et des données de défauts, permettant une **ingénierie de features** riche.

2. Gestion d'équipe

2.1. Organisation du travail

Le travail a été organisé en phases successives, calées sur le calendrier du cours.

Phase	Tâche principale	Date
1	Choix du dataset, formulation de la question	01/06/2026
2	Nettoyage, wrangling, exploration	01/06/2026
3	Visualisation et storytelling	02/06/2026
4	Feature engineering, régression	02–03/06/2026
5	Rédaction du rapport, préparation des slides	04/06/2026
6	Soutenance orale	05/06/2026

2.2. Répartition des rôles

- **Membre 1** — Chargé(e) de l'exploration des données, de la visualisation et du storytelling ;
- **Membre 2** — Chargé(e) du feature engineering et de la régression ;
- **Membre 3** — Chargé(e) de la rédaction du rapport et de la préparation des slides.

3. Description des données

3.1. Vue d'ensemble

Le dataset contient **207 lignes** et **41 colonnes**, couvrant trois familles de variables :

Famille	Variables clés	Type
Identité	Pays, Région, Ferme, Variété, Propriétaire	Catégorielle / texte
Agronomique	Altitude, Méthode de traitement, Couleur, Humidité	Numérique / catég.
Sensorielle	Aroma, Flavor, Aftertaste, Acidity, Body, Balance, Uniformity, Clean Cup, Sweetness, Overall, Total Cup	Numérique [6–10]
Défauts	Category One Defects, Category Two Defects, Quakers	Entier

3.2. Statistiques descriptives des critères sensoriels

Critère	Min	Q1	Médiane	Moyenne	Max
Aroma	6.50	7.58	7.67	7.72	8.58
Flavor	6.75	7.58	7.75	7.74	8.50
Aftertaste	6.67	7.42	7.58	7.60	8.42
Acidity	6.83	7.50	7.67	7.69	8.58
Body	6.83	7.50	7.67	7.64	8.25
Balance	6.67	7.50	7.67	7.64	8.42
Total Cup Points	78.00	82.58	83.75	83.71	89.33

Note : Les critères *Uniformity*, *Clean Cup* et *Sweetness* présentent des variances quasi nulles (presque tous égaux à 10 dans ce dataset premium), ce qui explique leur faible pouvoir prédictif.

3.3. Nettoyage et wrangling

- L'**altitude** est fournie comme texte libre ; elle a été convertie en numérique (`pd.to_numeric(..., errors='coerce')`), aboutissant à 153 valeurs valides sur 207.
- Les **méthodes de traitement** rares ($n = 1$) ont été regroupées en une catégorie « Autres » pour les analyses comparatives.
- La **couleur** des grains présente des incohérences typographiques (*yellow green* vs *yellow-green*) ; un nettoyage par normalisation de chaînes a été appliqué.

- **Aucune ligne n'a été supprimée** pour les analyses sensorielles (207 valeurs complètes).

4. Visualisation des données

4.1. Corrélations entre les critères sensoriels




Figure 1: Corrélogramme triangulaire inférieur des huit critères sensoriels ($n = 207$). Les couleurs chaudes indiquent une forte corrélation positive.

La figure 1 révèle que tous les critères sensoriels sont **fortement corrélés entre eux** ($r > 0.70$ pour la plupart), et en particulier avec le score total. Les corrélations les plus élevées avec le *Total Cup Points* sont : *Overall* ($r = 0.95$), *Flavor* ($r = 0.94$), *Aftertaste* ($r = 0.93$) et *Balance* ($r = 0.93$).

Un café arabica de qualité est un équilibre : aucun critère isolé ne suffit. La force du *Flavor* et de l'*Aftertaste* sont cependant les signaux les plus discriminants.

4.2. Profil sensoriel selon la méthode de traitement




Figure 2: Diagramme radar des profils sensoriels moyens selon la méthode de traitement. Les cafés « Natural/Dry » se distinguent par un Aroma et un Body plus prononcés.

La figure 2 compare trois méthodes : voie humide (*Washed*), voie sèche (*Natural*) et processus intermédiaire (*Honey/Pulped*). On observe que les cafés traités en voie sèche tendent à présenter un **arôme et un corps plus intenses**, tandis que les cafés lavés sont plus équilibrés sur l'ensemble des critères.

4.3. Scores par pays d'origine




Figure 3: Distribution du *Total Cup Points* pour les 12 pays les plus représentés. Les boîtes à moustaches sont ordonnées par médiane croissante. La ligne pointillée indique la moyenne globale (83,7 pts).

L'**Éthiopie** et la **Tanzanie** dominent le classement en termes de score médian (respectivement 85,0 et 84,7 pts), loin devant le Brésil et El Salvador qui peinent à dépasser 82 pts en médiane. Taiwan, très représenté ($n = 61$), affiche une médiane élevée (84,4 pts) avec une grande dispersion, témoignant d'une filière dynamique mais hétérogène.

4.4. Influence de l'altitude




Figure 4: *Gauche* : nuage de points altitude/score avec droite de régression. *Droite* : score moyen ($\pm$ IC à 95 %) par tranche d'altitude. La tendance positive est faible mais régulière au-delà de 1600 m.

La corrélation brute altitude-score est modeste ($r = 0.10$), mais la figure 4 révèle un effet de seuil : les cafés cultivés **au-delà de 1800 m** obtiennent en moyenne **84,8 pts**, soit +1,3 pt par rapport aux cafés cultivés sous 1000 m (83,5 pts). La faible corrélation s'explique par la multiplicité des facteurs confondants (pays, variété, méthode de traitement).

5. Feature Engineering

5.1. Variables directement disponibles (features brutes)

Les six critères sensoriels (*Aroma, Flavor, Aftertaste, Acidity, Body, Balance*) constituent nos features principales. Ils sont tous sur la même échelle [6–10] et normalement distribués, ce qui facilite l'application d'une régression linéaire.

5.2. Features construites

5.2.1. Score de qualité sensorielle globale

Inspiré du pipeline de feature engineering du cours (Lecture 4), nous construisons un **indice de qualité composite** :

$$\text{Sensory_Score} = \frac{\text{Flavor} + \text{Aftertaste} + \text{Balance}}{3} \quad (1)$$

Ce triplet concentre les critères les plus corrélés au score final et permet une réduction de dimensionnalité sans perte d'information majeure.

5.2.2. Pénalité de défauts

En nous inspirant de l'exemple de détection de fraude bancaire (Lecture 4 : $z = x_1^2 + x_2^2$), nous créons une variable synthétique combinant les deux types de défauts :

$$\text{Defect_Penalty} = \text{Cat1_Defects} \times 4 + \text{Cat2_Defects} + \text{Quakers} \quad (2)$$

La pondération ($\times 4$ pour les défauts de catégorie 1) reflète leur impact sensoriel plus sévère.

5.2.3. Encodage de l'altitude

L'altitude brute est convertie en une variable ordinale *Altitude_Band* (6 niveaux), puis one-hot encodée, conformément aux recommandations du cours (Lecture 2) sur les données ordinales à plusieurs catégories.

5.2.4. Encodage de la méthode de traitement

Les trois méthodes principales (*Washed, Natural, Honey/Pulped*) sont encodées par one-hot encoding (Lecture 2), les méthodes rares ($n = 1$) étant regroupées dans une catégorie « Autres ».

5.3. Vérification de la pertinence des features




Figure 5: Pertinence de deux features construites. La variété *Gesha* se démarque clairement (médiane $\approx 85,4$ pts). Les défauts de catégorie 2 et les *Quakers* montrent une corrélation négative marquée ($r = -0.32$ et $r = -0.32$).

6. Régression linéaire et logistique

6.1. Régression linéaire : prédire le score total

6.1.1. Modèle

Nous appliquons une régression linéaire multiple (Lecture 4) :

$$\widehat{\text{TCP}} = \beta_0 + \beta_1 \cdot \text{Aroma} + \beta_2 \cdot \text{Flavor} + \beta_3 \cdot \text{Aftertaste} + \beta_4 \cdot \text{Acidity} + \beta_5 \cdot \text{Body} + \beta_6 \cdot \text{Balance} + \varepsilon \quad (3)$$

Les variables sont standardisées (*StandardScaler*) avant l'estimation pour pouvoir comparer les coefficients.

6.1.2. Résultats

Critère	Coefficient standardisé	Interprétation
Flavor	0.345	Critère le plus influent
Aroma	0.333	
Aftertaste	0.331	
Balance	0.322	
Acidity	0.309	
Body	0.252	Critère le moins influent
Intercept	83.71	Score moyen de référence




Figure 6: Importance relative des critères sensoriels (coefficients standardisés de la régression linéaire). Un coefficient plus élevé signifie qu'une augmentation d'un écart-type du critère entraîne une plus forte hausse du score total.

Performance du modèle :

- $R^2 = 0.993$ (sur données d'entraînement) — le modèle explique 99,3 % de la variance ;
- $R_{CV}^2 = 0.676$ (validation croisée 5-fold) — performance robuste hors-échantillon ;
- RMSE = 0.149 point — l'erreur de prédiction est inférieure à 0,15 point.

La différence entre $R^2 = 0.99$ (in-sample) et $R_{CV}^2 = 0.68$ (out-of-sample) s'explique par le fait que le *Total Cup Points* est quasi-mécaniquement la somme des sous-scores dans le protocole CQI. Le modèle de régression est donc une quasi-tautologie : il capture la structure même du scoring CQI. Pour prédire la qualité d'un café *avant le cupping* (à partir de l'altitude, du pays, de la variété), un R^2 de 0.68 est en revanche réaliste.

6.2. Régression logistique : identifier les cafés d'exception

6.2.1. Définition de la cible

Nous définissons un café comme **d'exception** si son score dépasse 84 points :

$$Y = 1[\text{Total Cup Points} \geq 84] \quad (4)$$

Sur le dataset, 93 cafés (44,9 %) atteignent ce seuil.

6.2.2. Modèle LOGIT

Conformément au cours (Lecture 4) :

$$\ln \left(\frac{P(Y = 1|X)}{1 - P(Y = 1|X)} \right) = \beta_0 + \beta_1 \cdot \text{Aroma} + \dots + \beta_6 \cdot \text{Balance} \quad (5)$$

6.2.3. Résultats

Critère	Coefficient logistique
Aftertaste	1.804
Acidity	1.615
Aroma	1.546
Body	1.399
Flavor	1.189
Balance	1.186

Performance : Précision en validation croisée 5-fold = **89.9 %**. L'*Aftertaste* et l'*Acidity* sont les deux critères qui permettent le mieux de distinguer un café d'exception d'un café ordinaire.

7. Conclusion

7.1. Enseignements de l'analyse

Notre analyse du dataset CQI Arabica apporte des réponses concrètes à la question « *Quels critères définissent objectivement un café d'exception ?* » :

1. **Le Flavor et l'Aftertaste** sont les critères sensoriels les plus déterminants : c'est dans la persistance et la complexité des arômes que se joue l'excellence.
2. **L'origine géographique** compte : l'Éthiopie et la Tanzanie produisent structurellement des cafés plus notés, en lien avec leurs terroirs (altitude, variétés locales, pratiques de fermentation).
3. **La variété Gesha** se démarque avec un score moyen de 85,4 pts, justifiant son statut de café premium sur les marchés internationaux.
4. **L'altitude élevée** (> 1800 m) est associée à des scores supérieurs, mais l'effet reste modéré et masqué par d'autres facteurs.
5. **Les défauts** (Quakers, défauts de catégorie 2) ont un impact négatif mesurable ($r \approx -0.32$) et constituent une variable prédictive utile.

7.2. Limites et perspectives

- Le dataset ne compte que 207 observations, ce qui limite la puissance statistique, notamment pour les analyses par pays ou variété.
- Les notes CQI sont une mesure subjective (jury de Q-Graders) ; leur variabilité inter-juges n'est pas capturée.
- Une extension naturelle serait d'ajouter des données de **prix de marché** pour tester si le score CQI prédit effectivement la valeur commerciale du café.

- Un modèle plus sophistiqué (Random Forest, XGBoost) pourrait améliorer la prédiction à partir des seules variables agronomiques (pays, altitude, variété).

Références

1. Fillatre, L. (2025-2026). *Introduction to Data Processing — Lectures 1–4*. Polytech Nice Sophia, Université Côte d’Azur.
2. Coffee Quality Institute (CQI). *Arabica Coffee Quality Dataset*. Kaggle. <https://www.kaggle.com/datasets>
3. Wilke, C.O. (2019). *Fundamentals of Data Visualisation*. O’Reilly Media. <https://clauswilke.com/dataviz/>
4. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
5. Wexler, S., Shaffer, J., & Cotgreave, A. (2017). *The Big Book of Dashboards*. Wiley.