

L'anatomie d'un grand café arabica

Quels critères définissent objectivement un café d'exception ?

MAM3 · Introduction au Traitement de Données
Polytech Nice Sophia · Juin 2026

Dataset : CQI Arabica Quality (Kaggle) · $n = 207$ échantillons · 23 pays



Slide 1 — Business Goal

Le dataset CQI Arabica

Le Coffee Quality Institute (CQI) évalue des cafés arabica selon un protocole standardisé de *cupping* — 8 critères sensoriels notés de 0 à 10 par des juges certifiés Q-Grader.

207 échantillons | 23 pays |

41 variables

Score moyen : 83,7 / 100 | Max

: 89,3 pts

Quels facteurs — sensoriels, géographiques, variétaux — permettent de **prédire et d'expliquer** la qualité d'un café arabica certifié CQI ?



Score moyen par critère (échelle 6-10)




Slide 2 — Description des données

Structure du dataset

Famille	Variables
Identité	Pays, Variété, Ferme
Agronomique	Altitude, Méthode, Couleur
Sensorielle	9 critères + score total
Défauts	Cat.1, Cat.2, Quakers

Répartition géographique



Wrangling appliqué

- Altitude : texte → numérique (153/207 valides)
- Méthodes rares ($n = 1$) → regroupées « Autres »

44,9 % des cafés dépassent **84 pts**
⇒ seuil « café d'exception » retenu

Slide 3 — Features construites

3 nouvelles features créées

1. Indice sensoriel composite

$$\text{Sensory} = \frac{\text{Flavor} + \text{Aftertaste} + \text{Balance}}{3}$$

Concentre les 3 critères les plus prédictifs
($r > 0.93$)


2. Pénalité de défauts (inspirée Lecture 4)

$$\text{Penalty} = 4 \times \text{Cat1} + \text{Cat2} + \text{Quakers}$$

Corrélation avec le score : $r = -0.38$

3. Altitude en 6 bandes ordinales

Justification des features



Gauche : défauts Cat.2 vs score ($r = -0.31$). Droite :

Quakers vs score ($r = -0.32$)


La pureté du grain (peu de défauts) est aussi importante que ses arômes pour définir un bon café.



Slide 4 — Régression

Régression linéaire multiple

Variables : Aroma, Flavor, Aftertaste, Acidity, Body, Balance (standardisées)



Régression logistique

Cible : $Y = 1$ si score ≥ 84 pts (44,9 % positifs)

Critère	Coef. logit
---------	-------------

Aftertaste	1.80
------------	------

Acidity	1.62
---------	------

Aroma	1.55
-------	------

Body	1.40
------	------

Flavor	1.19
--------	------

Balance	1.19
---------	------


$$R^2 = 0.993 \text{ (train)} \quad R^2_{CV} = 0.676 \text{ (5-fold)}$$



Slide 5 — Conclusion

Ce que les données nous ont appris

- ✓ **Flavor & Aftertaste** — critères les plus déterminants : la persistance aromatique est la signature de l'excellence.
- ✓ **Éthiopie et Tanzanie** dominent le classement mondial (score médian > 84,7 pts).
- ✓ La variété **Gesha** se détache nettement (85,4 pts moyen).
- ✓ Haute altitude (> 1800 m) $\Rightarrow$ +1,3 pt en moyenne.
- ✓ **Défauts** (Quakers, Cat.2) pénalisent le score de façon mesurable ($r \approx -0.32$).




Score moyen par pays × méthode de traitement

Axes d'amélioration


- Ajouter les **prix de marché** pour valider l'impact




Storytelling — Un voyage mondial dans votre tasse



Storytelling — Le terroir en chiffres




L'altitude façonne le grain : au-delà de 1800 m, les nuits fraîches ralentissent la maturation et concentrent les arômes.



La méthode naturelle (voie sèche) amplifie le corps et l'arôme ; la voie humide favorise l'équilibre et la clarté.

Storytelling — La génétique du goût



La variété **Gesha**, originaire d'Éthiopie, domine les compétitions mondiales. Sa structure génétique produit des arômes floraux uniques, inimitables par les variétés commerciales.



Questions & Discussion

*« Le café est une question d'équilibre —
entre l'arôme et l'acidité, entre la science et l'art. »*

Dataset : CQI Arabica (Kaggle) · Dépôt Git : [URL] · MAM3 — 2025-2026