

Data Challenge : À la Recherche de la Tasse Parfaite

Storytelling des Déterminants de la Qualité du Café Arabica

Présenté par votre équipe

Analyse de Données Avancée

5 juin 2026

1. Business Goal : Quantifier l'Excellence du Café

Le Seuil Critique de la Spécialité

Score **Total Cup Points** ≥ 80 = Appellation "Café de Spécialité".

Un écart d'un seul point fait basculer radicalement la valeur marchande d'un lot.

Le Dataset

- Profil de **207 cafés Arabica**.
- Données physico-chimiques, environnementales et sensorielles.

Pourquoi cette analyse ?

- **Producteurs** : Identifier les leviers pour maximiser la note finale.
- **Négociants** : Prédire et sécuriser la qualité brute avant l'achat.

2. Data Description : Cartographie des Attributs

Structure du Dataset

- 207 lignes et 41 variables.
- **Cibles (Sensorielles)** : Aroma, Flavor, Aftertaste, Acidity, Body, Balance.
- **Physique & Défauts** : Catégories 1 & 2, Quakers, Moisture %.
- **Métadonnées** : Altitude, Procédé, Variété, Dates.

Défi Data : Forte multicolinéarité des notes gustatives. Focus nécessaire sur les variables physiques stables.




Figure – Forte corrélation transversale des attributs de tasse.

3. Handcrafted Features : Valoriser les Signaux Faibles

Pour enrichir nos modèles, nous avons conçu **3 transformations stratégiques** :

- **Procédés Harmonisés** : Regroupement en 3 grandes familles (*Washed*, *Natural*, *Pulped Honey*).
- **Paliers d'Altitude (Binned)** : Segmentation climatique non-linéaire (4 classes).
- **Âge du Café (Temporel)** : Temps écoulé entre la récolte et l'expiration.




Figure — Distribution croisée des scores selon nos features.

4. Régression : Caractéristiques Physiques

Approche globale


Prédiction du score final par régression multiple, en excluant strictement le goût (*Aroma, Flavor*, etc.).

Variables incluses

- **Physique** : Défauts, Quakers, Humidité, Couleur.
- **Contexte** : Altitude, Âge, Origine, Variété, Process.

Résultats clés

- **Pouvoir prédictif** : $R^2 \approx 0.53$ (plus de la moitié de la variance expliquée).
- **Impacts** : Fortes pénalités (défauts/quakers) vs primes au terroir.



Score prédit avec les caractéristiques physique ($R^2 \approx 0.53$)

5. Conclusion & Perspectives

Bénéfices de l'Analyse

- **Aide à la décision** : Choix du traitement optimal selon l'altitude de la plantation.
- **Gestion des risques** : Chiffrage direct de la perte de valeur liée aux défauts physiques.

Pistes d'Amélioration

- **Limites** : Faible échantillon à très haute altitude, manque de données macro-économiques.
- **Modélisation** : Passer sur du non-linéaire (*Random Forest*) ou de la régularisation (*Ridge/Lasso*).
- **Data** : Intégrer la pluviométrie et les températures régionales.

Merci pour votre attention. Place à vos questions !