

Data Challenge : À la Recherche de la Tasse Parfaite

Storytelling des Déterminants de la Qualité du Café Arabica

Présenté par votre équipe

Analyse de Données Avancée

5 juin 2026

1. Business Goal : Quantifier l'Excellence du Café

Le Seuil Critique de la Spécialité

Score **Total Cup Points** ≥ 80 = Appellation "Café de Spécialité".

Un écart d'un seul point fait basculer radicalement la valeur marchande d'un lot.

Le Dataset

- Profil de **207 cafés Arabica**.
- Données physico-chimiques, environnementales et sensorielles.

Pourquoi cette analyse ?

- **Producteurs** : Identifier les leviers pour maximiser la note finale.
- **Négociants** : Prédire et sécuriser la qualité brute avant l'achat.

2. Data Description : Cartographie des Attributs

Structure du Dataset

- 207 lignes et 41 variables.
- **Cibles (Sensorielles)** : Aroma, Flavor, Aftertaste, Acidity, Body, Balance.
- **Physique & Défauts** : Catégories 1 & 2, Quakers, Moisture %.
- **Métadonnées** : Altitude, Procédé, Variété, Dates.

Défi Data : Forte multicolinéarité des notes gustatives. Focus nécessaire sur les variables physiques stables.




Figure – Forte corrélation transversale des attributs de tasse.

3. Handcrafted Features : Valoriser les Signaux Faibles

Pour enrichir nos modèles, nous avons conçu **3 transformations stratégiques** :

- **Procédés Harmonisés** : Regroupement en 3 grandes familles (*Washed*, *Natural*, *Pulped Honey*).
- **Paliers d'Altitude (Binned)** : Segmentation climatique non-linéaire (4 classes).
- **Âge du Café (Temporel)** : Temps écoulé entre la récolte et l'expiration.




Figure — Distribution croisée des scores selon nos features.

4. Regression : L'Indice de Qualité Composite

Approche : Fusion Multidimensionnelle

Plutôt que des régressions isolées, nous avons condensé les facteurs clés en un seul **Indice de Qualité**.

La Formule Prédictive

Modèle de Régression Multiple

$$\text{Score} = 82.08 + \underbrace{0.001 \cdot \text{Alt}}_{\text{Bénéfice}} - \underbrace{0.216 \cdot \text{Def2}}_{\text{Pénalité}} + \underbrace{0.0009 \cdot \text{Âge}}_{\text{Stabilité}}$$

Interprétation des Poids

- **Défauts (Cat 2)** : Impact majeur. Un défaut de plus retire ≈ 0.2 pt.
- **Altitude** : Effet positif lié à une maturation lente.
- **Âge du grain** : Facteur de résilience temporelle.




Figure — Alignement : Indice Composite vs Note Réelle ($R^2 \approx 0.18$).

5. Conclusion & Perspectives

Bénéfices de l'Analyse

- **Aide à la décision** : Choix du traitement optimal selon l'altitude de la plantation.
- **Gestion des risques** : Chiffrage direct de la perte de valeur liée aux défauts physiques.

Pistes d'Amélioration

- **Limites** : Faible échantillon à très haute altitude, manque de données macro-économiques.
- **Modélisation** : Passer sur du non-linéaire (*Random Forest*) ou de la régularisation (*Ridge/Lasso*).
- **Data** : Intégrer la pluviométrie et les températures régionales.

Merci pour votre attention. Place à vos questions !