

À la Recherche de la Tasse Parfaite

Mesurer la Qualité du Café Arabica

Présenté par James, Evrard et Clément

Analyse de données sur les cafés de spécialité

5 juin 2026

1. Business Goal : Quantifier l'Excellence du Café

Le Seuil Critique de la Spécialité

Score **Total Cup Points** ≥ 80 = Appellation "Café de Spécialité".

Un écart d'un seul point fait basculer radicalement la valeur marchande d'un lot.

Le Dataset

- Profil de **207 cafés Arabica**.
- Données physiques, environnementales et sensorielles.

Pourquoi cette analyse ?

- **Producteurs** : Identifier les leviers de score.
- **Négociants** : Prédire la qualité avant l'achat.

2. Data Description : Cartographie des Attributs

Structure du Dataset

- 207 lignes et 41 variables.
- **Cibles** : Aroma, Flavor, Aftertaste, Acidity, Body, Balance.
- **Physique** : Défauts C1 & C2, Quakers, Humidité.
- **Métadonnées** : Altitude, Procédé, Variété.

Défi Data : Forte multicolinéarité des notes.
Focus sur les variables physiques et environnementales stables.




Figure — Forte corrélation transversale des attributs.

3. Handcrafted Features : Valoriser les Signaux Faibles

Pour enrichir nos modèles, nous avons conçu **3 transformations stratégiques** :

- **Procédés Harmonisés** : Regroupement en 3 grandes familles (*Washed*, *Natural*, *Pulped Honey*).
- **Paliers d'Altitude** : Segmentation climatique non-linéaire (4 classes) après correction des valeurs aberrantes.
- **Macro-Régions** : Regroupement géographique par grands terroirs (*Afrique*, *Amériques*, *Asie-Pacifique*) pour stabiliser les prédictions.




Figure – Distribution croisée des scores selon nos features.

4. Régression : Modèle d'Interaction sur l'Acidité

Approche par Croisement de Features


Nous modélisons le score d'**Acidité** via un effet d'interaction : l'impact de l'altitude dépend de la région du monde.

Modèle Linéaire d'Interaction (OLS)

$$\text{Acidity} \sim \text{Altitude} + \text{Région} + (\text{Altitude} \times \text{Région})$$

Interprétation Statistique

- **Pentes hétérogènes** : L'altitude sublime l'acidité différemment selon le terroir.
- **Significativité** : Capte des spécificités invisibles pour un modèle global.



Interaction Altitude $\times$ Région sur l'Acidité (3 tendances nettes).

5. Conclusion & Perspectives

Bénéfices de l'Analyse

- **Aide à la décision** : Choix du traitement optimal selon l'altitude.
- **Gestion des risques** : Chiffrage direct de l'impact des défauts physiques sur la valeur.

Pistes d'Amélioration

- **Enrichissement Data** : Intégrer la pluviométrie et les températures.
- **Classification Métier** :
 - *Régression Logistique* (Seuil ≥ 84) pour les lots d'exception.
 - *Régression Softmax* pour les classes SCA.
- **Modélisation** : Tester le *Random Forest*.

Merci pour votre attention. Place à vos questions !